

UA-A-LMC-VAE 改进方案简要报告

1. 原始 LMC-VAE 的限制

原始 LMC-VAE 对同一图像在两个噪声水平下的后验均值进行对称约束：

$$\mathcal{L}_{\text{LMC}} = \|\mu_l - \mu_h\|_2^2,$$

$$\text{LLMC} = \|\mu_l - \mu_h\|_2^2,$$

其中 μ_l 和 μ_h 分别是低噪声输入与高噪声输入对应的后验均值。该方法存在三个主要局限。

1.1 两个分支被视为同等可靠

对称损失会同时更新低噪声和高噪声分支。然而，低噪声输入通常保留更多语义信息，其表示一般更加可靠。让低噪声表示反向靠近高噪声表示，可能降低一致性目标的稳定性。

1.2 所有噪声对使用相同约束强度

原始损失没有考虑噪声水平。当高噪声输入接近纯噪声，或两个噪声水平相距较远时，仍然要求两个潜均值严格一致，可能产生过强的监督。

1.3 所有潜维度具有相同权重

VAE 编码器输出的后验方差反映了不同潜维度上的不确定性。原始 LMC 对所有维度使用相同权重，没有区分可靠维度与高不确定性维度。

2. 改进的总体方案

提出 **UA-A-LMC-VAE**：

Uncertainty-Aware Asymmetric Latent Mean Consistency VAE，即不确定性感知的非对称潜均值一致性 VAE。

该方案包括三个改进。

1. **非对称教师机制**：将低噪声分支作为停止梯度的语义目标，高噪声分支向低噪声分支学习。
2. **噪声自适应加权**：根据高噪声输入的信噪比以及两个噪声水平之间的距离，调整样本级一致性强度。
3. **不确定性感知加权**：根据后验方差，调整每个潜维度的一致性强度。

该方法直接复用 CoVAE 已有的两次编码结果，不增加网络结构、可训练参数或额外前向传播。

3. 输入和后验分布

对于输入图像 x ，构造低噪声和高噪声输入：

$$x_l = x + s_l \epsilon_l, \quad x_h = x + s_h \epsilon_h,$$

$$x_l = x + s_l \epsilon_l, \quad x_h = x + s_h \epsilon_h,$$

其中

$$s_l < s_h, \quad \epsilon_l, \epsilon_h \sim \mathcal{N}(0, I).$$

$$s_l < s_h, \quad \epsilon_l, \epsilon_h \sim \mathcal{N}(0, I).$$

编码器得到：

$$q_\phi(z | x_l) = \mathcal{N}(\mu_l, \text{diag}(v_l)),$$

$$q_\phi(z | x_l) = \mathcal{N}(\mu_l, \text{diag}(v_l)),$$

$$q_\phi(z | x_h) = \mathcal{N}(\mu_h, \text{diag}(v_h)).$$

$$q_\phi(z | x_h) = \mathcal{N}(\mu_h, \text{diag}(v_h)).$$

这里：

- s_l, s_h, v_l, v_h ：输入噪声尺度；
- $\mu_l, \mu_h \in \mathbb{R}^D$ ：后验均值；
- $v_l, v_h \in \mathbb{R}^D$ ：后验方差；
- D ：潜变量维度。

使用不同符号 s 和 v ，是为了区分输入噪声尺度与编码器后验方差。

4. 新的一致性损失

4.1 非对称均值误差

首先定义：

$$e_{i,d} = (\mu_{h,i,d} - \text{sg}(\mu_{l,i,d}))^2,$$

$$e_{i,d} = (\mu_{h,i,d} - \text{sg}(\mu_{l,i,d}))^2,$$

其中：

- i 表示 batch 中第 i 个样本；
- d 表示第 d 个潜维度；
- $\text{sg}(\cdot)$ 表示 stop-gradient。

该误差要求高噪声分支恢复出接近低噪声分支的语义表示。停止梯度使新增损失只通过高噪声分支反向传播，避免高噪声表示反向拉动低噪声目标。

低噪声分支仍然会通过重建损失、KL 损失和原始像素一致性损失正常训练。

4.2 噪声自适应权重

对于加性噪声过程，可近似定义：

$$\text{SNR}(s) = \frac{1}{s^2 + \varepsilon}.$$

$$\text{SNR}(s) = \frac{1}{s^2 + \varepsilon}.$$

若 CoVAE 已经提供 α_t 和 σ_t ，则可使用：

$$\text{SNR}(t) = \frac{\alpha_t^2}{\sigma_t^2 + \varepsilon}.$$

$$\text{SNR}(t) = \frac{\alpha_t^2}{\sigma_t^2 + \varepsilon}.$$

高噪声分支的可靠性权重定义为：

$$w_{\text{conf},i} = \left(\frac{\text{SNR}_{h,i}}{\text{SNR}_{h,i} + \kappa} \right)^\gamma.$$

$$w_{\text{conf},i} = \left(\frac{\text{SNR}_{h,i}}{\text{SNR}_{h,i} + \kappa} \right)^\gamma.$$

其中：

- $\kappa > 0$ $\kappa > 0$ ：控制权重的转折位置；
- $\gamma > 0$ $\gamma > 0$ ：控制权重变化速度；
- $\text{SNR}_{h,i}$ $\text{SNR}_{h,i}$ ：第 i 个高噪声输入的信噪比。

高噪声输入的 SNR 越低，其一致性权重越小。

进一步定义噪声距离权重：

$$w_{\text{gap},i} = \exp[-\eta |\log \text{SNR}_{l,i} - \log \text{SNR}_{h,i}|],$$

$$w_{\text{gap},i} = \exp[-\eta |\log \text{SNR}_{l,i} - \log \text{SNR}_{h,i}|],$$

其中 $\eta \geq 0$ $\eta \geq 0$ 控制噪声距离的衰减速度。两个噪声水平距离越远，该权重越小。

最终样本级权重为：

$$w_{\text{noise},i} = w_{\text{conf},i} w_{\text{gap},i}.$$

$$w_{\text{noise},i} = w_{\text{conf},i} w_{\text{gap},i}.$$

如果 CoVAE 始终使用相邻时间步，可以将 w_{gap} w_{gap} 设为 1，并通过消融实验判断该项是否必要。

4.3 不确定性感知权重

根据两个分支的后验方差，定义第 d 个潜维度的置信度：

$$u_{i,d} = \frac{1}{v_{l,i,d} + v_{h,i,d} + \epsilon}.$$

$$u_{i,d} = v_{l,i,d} + v_{h,i,d} + \epsilon 1.$$

后验方差越小，说明该维度越可靠，其一致性权重越大。为提高数值稳定性，定义：

$$w_{\text{unc},i,d} = \text{sg}[\text{clip}(u_{i,d}, u_{\min}, u_{\max})].$$

$$w_{\text{unc},i,d} = \text{sg}[\text{clip}(u_{i,d}, u_{\min}, u_{\max})].$$

其中：

- $u_{\min}$ $u_{\min}$ ：权重下界；
- $u_{\max}$ $u_{\max}$ ：权重上界；

- ε : 防止除零的常数;
- clip: 截断操作。

对该权重停止梯度非常重要，否则模型可能通过增大后验方差来减小一致性损失。

为稳定不同训练阶段的损失尺度，可将其归一化为：

$$\widetilde{w}_{\text{unc},i,d} = \frac{w_{\text{unc},i,d}}{\frac{1}{BD} \sum_{j=1}^B \sum_{k=1}^D w_{\text{unc},j,k} + \varepsilon},$$

W

$$\text{unc},i,d = \frac{1}{BD} \sum_{j=1}^B \sum_{k=1}^D w_{\text{unc},j,k} + \varepsilon w_{\text{unc},i,d},$$

其中 B 为 batch size。

4.4 完整损失

最终的不确定性感知非对称潜均值一致性损失为：

$$\mathcal{L}_{\text{UA-A-LMC}} = \frac{1}{BD} \sum_{i=1}^B \sum_{d=1}^D w_{\text{noise},i} \widetilde{w}_{\text{unc},i,d} (\mu_{h,i,d} - \text{sg}(\mu_{l,i,d}))^2$$

$$\text{LUA-A-LMC} = \frac{1}{BD} \sum_{i=1}^B \sum_{d=1}^D w_{\text{noise},i} w_{\text{unc},i,d} (\mu_{h,i,d} - \text{sg}(\mu_{l,i,d}))^2$$

$$\text{unc},i,d (\mu_{h,i,d} - \text{sg}(\mu_{l,i,d}))^2$$

该损失可以理解为：

潜均值误差 × 噪声对可靠性 × 潜维度可靠性。

潜均值误差 × 噪声对可靠性 × 潜维度可靠性。

总训练目标为：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{recon}} + \lambda_{\text{KL}} \mathcal{L}_{\text{KL}} + \lambda_{\text{pixel}} \mathcal{L}_{\text{pixel}} + \lambda_{\text{UA}} \mathcal{L}_{\text{UA-A-LMC}}$$

$$\text{Ltotal} = \text{Lrecon} + \lambda_{\text{KL}} \text{LKL} + \lambda_{\text{pixel}} \text{Lpixel} + \lambda_{\text{UA}} \text{LUA-A-LMC}$$

其中：

- $\mathcal{L}_{\text{recon}}$ Lrecon：重建损失；

- $\mathcal{L}_{\text{KL}}$ LKL: VAE 后验与先验之间的 KL 散度;
- $\mathcal{L}_{\text{pixel}}$ Lpixel: CoVAE 原有的输出空间一致性损失;
- $\mathcal{L}_{\text{UA-A-LMC}}$ LUA-A-LMC: 新增的潜空间一致性损失;
- λ_{KL} $\{\mathrm{KL}\}$ λ_{KL} 、 λ_{pixel} $\{\mathrm{pixel}\}$ λ_{pixel} 、 λ_{UA} λ_{UA} : 各损失的权重。

建议对 λ_{UA} λ_{UA} 使用预热:

$$\lambda_{\text{UA}}(r) = \lambda_{\text{max}} \min\left(1, \frac{r}{R}\right),$$

$$\lambda_{\text{UA}}(r) = \lambda_{\text{max}} \min(1, Rr),$$

其中 rr 为当前训练步数, RR 为预热步数, 避免训练初期使用尚不可靠的低噪声表示作为强监督目标。

5. 实现思路

每个训练 batch 的实现过程如下:

1. 采样 $s_l < s_h$ $\langle shsl < sh$, 构造 x_l/x_l 和 x_h/hxh ;
2. 使用同一个编码器得到 $(\mu_l, \log v_l)/l, \log v_l$ $(\mu_l, \log v_l)$ 和 $(\mu_h, \log v_h)/h, \log v_h$ $(\mu_h, \log v_h)$;
3. 按原 CoVAE 流程计算重建、KL 和像素一致性损失;
4. 根据噪声尺度计算 w_{noise} w_{noise} ;
5. 由 $\log v_l, \log v_h/l, \log v_h$ $\log v_l, \log v_h$ 计算后验方差和 w_{unc} w_{unc} ;
6. 对 μ_l/μ_l 和权重执行 detach;
7. 计算 $\mathcal{L}_{\text{UA-A-LMC}}$ LUA-A-LMC , 加入总损失并反向传播。

由于所有均值和方差已经在 CoVAE 的前向传播中得到, 因此仅增加少量逐元素运算。

6. 需要补充的实验

6.1 主要对比实验

至少比较以下方法:

方法	说明
VAE	标准基线
CoVAE	原始一致性模型
LMC-VAE	对称、固定权重的均值一致性
UA-A-LMC-VAE	完整改进方法

应在相同架构、优化器、随机种子、训练步数和评估流程下比较。

除 MNIST 外，建议至少增加一个复杂数据集，例如 CIFAR-10 或 Fashion-MNIST。若计算资源允许，可进一步使用 CelebA。

6.2 模块消融实验

使用逐步添加模块的方式验证各部分贡献：

编号	非对称教师	SNR 权重	噪声距离权重	不确定性权重
A	否	否	否	否
B	是	否	否	否
C	是	是	否	否
D	是	是	是	否
E	是	是	是	是

其中 A 对应原始 LMC-VAE，E 对应完整方法。重点验证：

- stop-gradient 是否提高稳定性；
- SNR 权重是否改善高噪声阶段；
- w_{gap} 是否真正有效；
- 后验方差加权是否优于统一权重。

6.3 超参数实验

建议测试：

$$\lambda_{\text{UA}} \in \{0.05, 0.1, 0.2, 0.5\},$$

$\lambda_{UA} \in \{0.05, 0.1, 0.2, 0.5\}$,

以及不同的：

- κ ：SNR 权重转折位置；
- γ ：SNR 权重变化速度；
- η ：噪声距离衰减系数；
- $u_{\min}, u_{\max}$ ：不确定性权重截断范围；
- R ：一致性损失预热步数。

6.4 生成与重建指标

建议报告：

- 一步和多步生成 FID；
- Reconstruction FID；
- PSNR、SSIM；
- 如果使用自然图像，增加 LPIPS；
- 不同训练步数下的性能曲线；
- 达到指定 FID 所需的训练步数和时间。

应同时报告等步数和等时间预算下的结果，例如所有方法均在 100k、200k、320k 和 400k 步进行比较。

6.5 噪声鲁棒性实验

在不同输入噪声水平下测试：

- 重建 FID；
- PSNR/SSIM；
- 潜均值漂移：

$$\Delta_{\mu}(s) = \mathbb{E}_x [\|\mu(x_s) - \mu(x)\|_2].$$

$$\Delta_{\mu}(s) = \mathbb{E}_x [\|\mu(x_s) - \mu(x)\|_2].$$

该实验可直接验证模型是否学到了更稳定的噪声不变表示。

6.6 潜空间与坍塌分析

为了确认一致性正则没有造成潜空间收缩，建议报告：

- batch 内潜均值方差；
- 平均 KL；
- Active Units；
- 潜变量协方差的有效秩；
- 潜表示线性分类准确率；
- 类内距离和类间距离。

理想结果是：同一样本跨噪声的距离减小，但不同样本或不同类别之间仍保持足够区分度。

6.7 重复实验与计算开销

每个主要实验至少运行 3~5 个随机种子，报告：

mean $\pm$ standard deviation.

mean $\pm$ standard deviation.

同时比较：

- 单步训练时间；
- 峰值显存；
- 参数量；
- 总训练时间。

这可以验证“无需额外参数、仅有可忽略计算开销”的结论。

7. 预期贡献

该方案将原始固定、对称的潜均值一致性扩展为一个具有方向性和可靠性建模的目标：

1. 低噪声表示作为稳定语义目标；
2. 根据输入噪声质量调整样本级监督强度；
3. 根据后验不确定性调整潜维度级监督强度；
4. 保持无额外参数和无额外前向传播的轻量特性。

相较于原始 LMC-VAE，新的方法不再简单假设“所有表示都应被等强度地对齐”，而是强调：

只在目标足够可靠时，对可信的潜维度施加更强的一致性约束。